

Tekst oratie prof. Dr. Peter Lugtig

Rede uitgesproken op 2 april 2026, Utrecht ter aanvaarding van het hoogleraarschap 'datakwaliteit'.

Mevrouw de rector, zeergeleerde collega's, geachte aanwezigen,

Ik wil jullie iets vertellen over datakwaliteit. Als het goed is ziet u onder op de beeldschermen hier naast me Engelse ondertitels. Als de techniek ons tenminste niet in de steek laat. En ik een beetje duidelijk blijf praten, want het programma dat de vertaling vandaag verzorgt moet eerst mijn uitgesproken tekst omzetten naar geschreven tekst. En dan van die geschreven Nederlandse tekst een vertaling vinden in het Engels. En dat ook nog doen zonder dat het programma weet waar mijn verhaal nou eigenlijk heengaat.

Er kan van alles misgaan in de vertaling van het Nederlands naar het Engels; en dat gaat ongetwijfeld wel gebeuren, zeker richting het einde zo kan ik alvast verklappen. Maar er kan ook van alles misgaan in het omzetten van mijn woorden in geschreven tekst, bijvoorbeeld als ik niet zo duidelijk praat of te snel. Ik ga proberen de komende 45 minuten data van goede kwaliteit uit mijn mond laten komen. Als dat niet lukt kan ik altijd nog de schuld geven aan het vertaalsysteem.

Data is niks anders dan informatie die we voor iets gebruiken. We gebruiken data voor alledaagse beslissingen, maar ook voor serieus beleid en keuzes. We gebruiken data over leerprestaties om te beslissen naar welk niveau middelbare school we kinderen sturen, en hoe we ons sociaal vangnet in Nederland moeten inrichten. Maar u gebruikte ook data om te bepalen of u nou dat vestje wel of niet moest aantrekken hierbinnen. We gebruiken data altijd en overal.

Ik wil jullie in de komende 45 minuten vertellen dat datakwaliteit meer is dan 'of cijfers zo'n beetje kloppen', en ook waarom we in deze tijd, waarin we te maken hebben met wellicht belangrijker zaken als oorlog in Europa, het Midden-Oosten en klimaatverandering op de universiteit toch ook vooral nieuwe vragen rond datakwaliteit moeten oplossen, zeker in de sociale

wetenschappen. Om goede maatschappelijke discussies te kunnen voeren over belangrijke thema's als armoede is het volgens mij heel belangrijk dat we goede en onafhankelijke data hebben. Goede en gezamenlijk gedragen feiten kunnen helpen voorkomen dat we langs elkaar heen praten, zeker in een tijd waarin sommige mensen geneigd zijn alle data die ze zien gelijkwaardig te wegen.


Methodologie – hoe doen we onderzoek?

Maar laat ik beginnen bij het begin. Ik werk hier in Utrecht bij de faculteit sociale wetenschappen, waar onderzoek wordt gedaan naar allerlei belangrijke vragen van deze tijd. Hoe kunnen we ervoor zorgen dat kinderen op een goede manier opgroeien? Hoe kunnen we betere behandelingen vinden voor depressies en andere mentale problemen? En hoe kunnen we allerlei vormen van ongelijkheid in onze samenleving begrijpen, en daar iets tegen doen? Sociale wetenschappers in Utrecht houden zich al bijna 80 jaar bezig met dit soort vragen, en hoewel het type vragen dat we ons stellen in de wetenschap heus wel wat is veranderd met de tijd zijn dit allemaal vragen die collega's van mij zich ook 60 jaar geleden ook al stelden.

Ook als het gaat om hoe je antwoorden vindt op dit soort vragen is er sprake van continuïteit. Een deel van de sociale wetenschappen houdt zich altijd al bezig met wat we noemen theorievorming. Ze denken na over wat ongelijkheid bijvoorbeeld inhoudt; gaat dat alleen om materiele ongelijkheid, of ook om dingen die je niet direct kunt zien zoals gezondheid of digitale ongelijkheid. Onze maatschappij verandert voortdurend, en je kunt vanuit nieuwe invalshoeken ook problemen die er al lang zijn op een nieuwe manier bekijken.

Een ander deel van de wetenschap houdt zich ook – of vooral – bezig met beschrijving en theorietoetsing. Ze bekijken in de werkelijkheid hoe je ongelijkheid kunt meten, hoe ongelijkheid zich ontwikkelt, en bijvoorbeeld tussen welke groepen ongelijkheid bestaat. Deze vorm van sociale wetenschap heeft als doel de werkelijkheid te beschrijven en verklaren. Goede wetenschappers doen vaak een beetje van allebei: ze denken na over hoe je ongelijkheid zou kunnen begrijpen of verklaren – dus aan theorievorming - en ze toetsen daarna of hun theorieën ook kloppen met de werkelijkheid.

Over hoe je goed onderzoek moet doen zijn de afgelopen honderd jaar ideeën ontwikkeld die aansluiten bij deze praktijk van theorievorming, en theorietoetsing. Eerstejaarsstudenten sociale wetenschappelijk worden in hun onderwijs bij ons in Utrecht doodgegooid met het volgende plaatje dat ontleend is aan het werk van de Nederlander Adriaan Groot, en alleen daarom al vond ik het passend dat ook hier te laten zien.



2

Het plaatje staat voor de empirische cyclus. Centraal in de empirische cyclus staan twee ideeën: Eerst het idee dat onderzoek een cyclus is, waarbij het oplossen van vragen meestal weer tot nieuwe vragen leidt, en uiteindelijk tot de langzame toename van collectieve kennis.

Het tweede centrale idee van de empirische cyclus is dat er binnen een onderzoek logische stappen zijn die op elkaar volgen, en als elke stap netjes wordt doorlopen, dan leidt dat tot goed onderzoek. Goede data komen dus vanzelf als je een onderzoeksproces goed opzet.

Voor deze lezing richt ik me met name op de stap waarin door de onderzoeker wordt nagedacht over het onderzoeksontwerp. Dat is het vakgebied van de methodologie: hoe zorg je voor een goede methode om op een wetenschappelijke manier een antwoord te krijgen op je onderzoeksvragen?

Het onderzoekswerp, dus hoe je onderzoek precies uitvoert noem ik in deze lezing de datamachine. Je gooit een vraag in de machine, en als je de machine goed instelt door op de juiste onderzoeksknoppen te drukken, dan komt er uiteindelijk een mooi en goed antwoord uitgerold. Als je wilt zorgen voor goede datakwaliteit moet je zorgen voor een goede datamachine.

Onderzoeksontwerp: de datamachine



3

Wanneer een onderzoeker bijvoorbeeld wil weten of antidepressiva en een therapie samen beter werken dan alleen een therapie bij het behandelen van mensen met depressiviteit, dan ligt het voor de hand om een experiment uit te voeren. Soms wil je als onderzoeker mensen interviewen, bijvoorbeeld om goed te kunnen begrijpen wat iemand van iets vindt. Dit kan met vragenlijsten of met open interviews.

Voor elke onderzoeksmethode is in de loop van de 20^e eeuw een set van regels, principes of in het Engels 'best-practices' ontwikkeld en vervolmaakt. Voor experimenten kent u misschien wel de regels van het willekeurig toewijzen van mensen aan experimentele condities en dat het liefst ook blind voor de onderzoeker.

Die regels kun je samenvatten in de datamachine. We krijgen goede data als we een goede machine hebben gebouwd, en daarna netjes de stappen volgen in het onderzoek. En vaak gaat het gelukkig ook zo in de wetenschap. Maar langzaamaan is er de afgelopen decennia wat veranderd in de wereld van het onderzoek, die maken dat ik hier nu sta, en u hier nu zit.

Wat gaat er mis met onze data-machine

Er is de laatste 30 jaar – zo'n beetje gelijktijdig met de enorme digitalisering die het Internet tot gevolg heeft gehad iets veranderd in veel sociaalwetenschappelijk onderzoek.

1. Er is een steeds **grotere behoefte aan informatie**. En die informatie moet er vaak sneller zijn, en liefst niet te veel kosten.
2. Er waren altijd al **moeilijkheden** in het doen van sociaalwetenschappelijk onderzoek, vooral als het gaat om het zorgen dat de juiste mensen meedoen, en dat we meten wat we willen meten. Maar die problemen worden groter
3. Er is veel **meer data** zomaar beschikbaar.


Laat ik wat langer stilstaan bij elk van deze drie uitdagingen.

Waarom hapert de datamachine?

1. Grotere behoefte aan informatie
2. Moeilijkheden in onderzoek
3. Meer data beschikbaar



Source: house of commons library: <https://commonslibrary.parliament.uk/has-labour-market-data-become-less-reliable/>



4

Er is meer behoefte aan informatie; dit geldt voor de wetenschap zelf, maar vooral ook voor de maatschappij. Overheden, bedrijven en maatschappelijke organisaties zijn allemaal bezig met programma's rond datagedreven sturing. Vaak vanuit een idee dat we daarmee ons werk of beleid beter of vaker nog: efficiënter kunnen maken.

U wordt bij elke aankoop die u doet gevraagd een review te schrijven, bij het maken van beleid zijn draagvlakmetingen tegenwoordig heel gewoon, en in het onderwijs worden de leerlingprestaties continue bijgehouden. Of het verzamelen van al deze data nu echt altijd zinvol is laat ik even in het midden – vaak wel maar ook vaak niet, maar er is een nog steeds groeiende behoefte aan informatie en data. Dit betekent meer onderzoek, en al dat onderzoek goed uitvoeren kost heel veel tijd en geld, dat er soms niet is.

Dan, moeilijkheden in onderzoek. Mensen geven niet altijd eerlijk antwoord als je iets vraagt als onderzoeker. Op sommige vragen – zoals hoeveel stappen u vandaag heeft gezet – weten mensen simpelweg het antwoord niet. En – een meer recent probleem: mensen hebben vaak steeds minder zin om mee te doen aan onderzoek. Nonrespons is bij al het onderzoek een steeds groter probleem aan het worden. U ziet hier rechts op het scherm een plaatje van het percentage mensen dat per kwartaal meedoet aan de Engelse Labour Force Survey. Dit is een belangrijk onderzoek waar bijvoorbeeld de werkloosheid mee wordt geschat; In Engeland is de respons in dit onderzoek gedaald van ongeveer 80% in 2001 naar 30% in 2023. En slechts 15% maakt dit onderzoek af. Is dat nou erg? Een lage respons hoeft niet erg te zijn, maar in Engeland zien ze ook grote schommelingen door de tijd heen in schattingen van het aantal werklozen; zo erg zelfs dat ze meerdere malen besloten hebben dat de data niet goed genoeg waren om te gebruiken. Is dat erg? Ja.

Want deze data worden gebruikt om overheidsbeleid te maken rond uitkeringen en belastingen, en hoe doe je dat zonder goede data? Dit voorbeeld uit Engeland is gelukkig nog vrij zeldzaam, maar we zien in vrijwel al het onderzoek een dalende respons, en zeker sinds Corona zijn er ook zorgen dat we met sociaalwetenschappelijk onderzoek bepaalde groepen in de samenleving helemaal niet meer goed bereiken.

Natuurlijk zijn er wel oplossingen. Je kunt meer moeite doen om mensen bij onderzoek te betrekken; maar dat maakt onderzoek steeds duurder. En er zijn ook andere oplossingen die aansluiten bij de redenen dat mensen minder geneigd zijn om zomaar mee te doen. Ik kom daar nog op terug.

Tenslotte, er is steeds meer data vrijelijk beschikbaar. Vooral door digitalisering en het Internet worden er veel meer data worden verzameld. Informatie die online staat op sociale media kan wellicht best zinvol zijn voor het begrijpen van opvoeding in Nederland, dat voelt iedereen wel aan. We kunnen op YouTube bijvoorbeeld tellen hoeveel kinderen in Nederland een eigen vlog hebben en coderen wat ze daar vertellen en doen, en welke rol hun ouders spelen. Het tellen kan tegenwoordig met AI, en met webscraping kunnen we al die data van Internet afhalen. Ja, er is meer en meer data, maar wat doen we daarmee?


Dus: Traditioneel onderzoek wordt moeilijker en duurder. En aan de andere kant leven we in een wereld waarin allerlei data zomaar, vaak gratis en heel snel beschikbaar zijn. Die twee werelden botsen. Dat lijkt misschien een

theoretische botsing, maar het is heel praktisch. Veel wetenschappers staan voor de vraag of ze vasthouden aan traditionele methodes van onderzoek via bijvoorbeeld vragenlijsten, of dat ze overstappen naar het gebruik van nieuwe databronnen en big data voor het beantwoorden van hun onderzoeksvragen. En heel veel mensen worstelen daarmee. Al die nieuwe data lijken heel bruikbaar, maar hoe? Data in overvloed, maar wat doen we ermee?

Hoe nu verder

We hebben behoefte aan een nieuwe datamachine waarin we de oude machines die we al hadden blijven gebruiken, maar aanvullen. Maar hoe doen we dat nu op een goede manier? Dat is nu precies waar ik me de komende jaren in mijn onderzoek en onderwijs mee bezig wil houden.

Een nieuwe datamachine?



5

Hoe zou een nieuwe datamachine er uit moeten zien? Die is in ieder geval een stuk complexer dan vroeger, omdat onderzoekers bestaande data – en allerlei vormen nieuwe data – op allerlei manieren met elkaar kunnen combineren. Hoe je dat doet hangt af van het onderwerp, en welke data je hebt. Er is geen recept voor hoe al die data samen te voegen en samenvatten. Er is dus ook niet 1 datamachine.


Maar laten we eens een poging doen. Hoe ziet de onderzoeksmethodologie van een toekomst eruit waarin we ook in de sociale wetenschappen veel meer werken met bestaande en digitale data?

Een belangrijk verschil met de oude datamachine is dat we er niet meer zomaar op kunnen vertrouwen dat data vanzelf goed zijn als we het dataverzamelingsproces maar goed ontwerpen. Het proces is op zich nog steeds belangrijk, maar niet genoeg om iets te zeggen over de data die we uiteindelijk krijgen, zeker niet als die data op allerlei manieren aan elkaar is geplakt. Kwaliteit wordt bepaald door de kwaliteit van elke bron, maar ook de kwaliteit van hoe we dingen aan elkaar knopen.

Hierbij zijn we aangekomen bij 1 belangrijke verandering in hoe we denken over methodologie in een wereld met een overvloed aan data. In plaats van te kijken naar de kwaliteit van het proces is het productiever om te kijken naar de kwaliteit van de uiteindelijke data, en na te denken over waar die data aan moeten voldoen. Hier is al eerder over nagedacht. Paul Biemer en Lars Lyberg hebben een kader ontwikkeld dat generiek is en gebruikt kan worden om te kijken wanneer data nu eigenlijk goed zijn en wanneer niet. Ik heb niet de tijd om hun hele werk te bespreken, maar zal een aantal aspecten bespreken. Hoe zien onze ideale data eruit?

Data kwaliteit: output

- Accuraat
- Tijdig
- Compleet
- Relevant
- Toegankelijk
- Geloofwaardig
- Vergelijkbaar
- Coherent
- Interpreteerbaar



Biemer, P. P., & Lyberg, L. E. (2003). *Introduction to survey quality*. John Wiley & Sons.

6

- Accuraat: In de wetenschap is een van de belangrijkste doelen dat we data hebben die accuraat is. Dat we meten wat we willen meten, en dat ook precies doen. Dus een thermometer moet meten hoe warm onze oven is, en dat ook precies doen zodat we weten dat de cake die we aan het bakken zijn ook echt klaar is na een uur.
- Tijdig: We willen graag ook dat niet zo lang hoeven te wachten op onze data. De data moeten op tijd beschikbaar zijn. We moeten onder ogen zien dat de sociale wetenschappen vaak heel traag zijn in het produceren van data, en dat dataverzamelingen vaak ook enorm duur zijn. In de wetenschap is er een beweging van “slow science” waarin we juist de tijd neen om dingen goed uit te zoeken. Slow science is mooi voor de wetenschap, maar voor bijvoorbeeld het evalueren van beleid is snelheid vaak heel belangrijk. Willen we snel iets weten, dan nemen we

wellicht genoeg met data die minder precies zijn. Biemer en Lyberg vinden dat ook een vorm van datakwaliteit.

Een voorbeeld uit de praktijk waar we in Utrecht aan hebben gewerkt is data die werd gebruikt tijdens de Covid-periode. U weet het vast nog; aan het begin van de pandemie waren er allerlei adviezen. 1.5 meter afstand, er waren allerlei plekken dicht zoals zwembaden en verenigingen, weinig of geen sociale contacten en thuiswerken. De overheid wilde graag weten in hoeverre die adviezen nu werden opgevolgd door mensen. 1 van de belangrijkste was of mensen vaker thuis bleven. Dit kun je natuurlijk aan mensen vragen, en dat is ook gedaan, bijvoorbeeld door het RIVM. Maar de overheid wilde graag weten hoe mensen de adviezen opvolgden en graag zo snel mogelijk; er was echt grote haast bij. Omdat de sociale wetenschappen niet snel goede data konden leveren werd er meer vertrouwd op data van bijvoorbeeld Apple en google over het reisgedrag van mensen dat werd gemeten via mobiele telefoons. Hier zien jullie een plaatje van mobiliteitsdata van google dat laat zien hoe het reisgedrag gemeten in waar mensen naar toe gaan is veranderd gedurende het eerste jaar van de Covid-pandemie. Samen met Angelo Moretti en Katharina Meitinger bekeken we over verschillende beleidsterreinen, dus niet alleen naar mobiliteitsdata, naar de kwaliteit van de gebruikte data tijdens Covid, en ook hoe je in een toekomstige pandemie betere data kunt krijgen. Mobiele telefoniedata zijn wel heel tijdig, maar het zal u niet verbazen wellicht dat de mobiliteitsdata niet precies meten of mensen zich aan de richtlijnen hielden. Ze meten heel grof of er meer mensen in parken, winkels of bijvoorbeeld werk zijn, waarbij Google natuurlijk ook niet precies weet of u bijvoorbeeld hier vandaag komt om te werken, voor iets sociaals, of te winkelen (ja, we hebben hier een UU-winkel).

Er zijn nog meer kwaliteitscriteria. We willen graag dat data compleet zijn. Nu zijn er ontzettend veel telefoons in Nederland, maar niet iedereen heeft een telefoon van google. Er zijn ook Apple telefoons, en we weten uit onderzoek dat die telefoons niet alleen een ander soort gebruikers heeft, maar dat die mensen ook een ander soort reisgedrag hebben. En uiteraard gaan we er bij de mobiliteitsdata vanuit dat iedereen zijn of haar mobiele telefoon altijd bij zich heeft, en aan heeft staan. Maar we weten ook dat dat niet zo is. Dus de data van Google zijn verre van compleet.

Nog een probleem met de mobiliteitsdata is de relevantie. Zelfs als we kunnen zien dat mensen minder naar hun werk gingen, dan nog kunnen we geen onderscheid maken tussen verschillende type mensen, de leeftijden van die mensen, of bijvoorbeeld het type werk dat ze hadden. Sommige mensen - die met een cruciaal beroep - werkten bijvoorbeeld gewoon door en daar wil je wel rekening mee houden in de evaluatie van beleid.. Daarvoor zou je dan toch graag vragenlijsten, of bijvoorbeeld interviews gebruiken.

Behalve deze kwaliteitscriteria zijn er nog vijf die ik hier niet uitgebreid zal behandelen. Twee hebben met de producent van de data te maken. Als het RIVM-onderzoek doet naar vaccins dan zijn de data uit hun onderzoek daaruit **geloofwaardiger** – althans volgens de meeste mensen – dan als dat ik dat onderzoek zou uitvoeren vanachter mijn laptop op zolder. De **toegankelijkheid** heeft te maken met de data zelf of die beschikbaar zijn. Data zijn idealiter ook **vergelijkbaar**. Bijvoorbeeld vergelijkbaar over groepen mensen; als we in het onderwijs een toets afnemen dan willen we dat die toets dat op eenzelfde eerlijke manier doet voor bijvoorbeeld jongens en meisjes. Tenslotte moet de data ook **interpreteerbaar** zijn – we moeten er eventueel na analyses chocola van kunnen maken, en moet de data samenhangend zijn (of **coherent**).

Als we na willen denken over een wereld waarin we allerlei verschillende databronnen samen willen gebruiken, dan is het belangrijk om na te denken over hoe we door data samen te nemen, de kwaliteit van de uiteindelijke data kunnen verhogen. Een belangrijk principe is dat we voor elke databron bekijken op welke kwaliteitsaspecten die goed of slecht scoort als het gaat om kwaliteit. Daarna kunnen we proberen om de zwakke kanten van bepaalde databronnen op te lossen met het met andere databronnen die op die gebieden beter scoren.

Dit is waar ik via mijn leerstoel in Utrecht samen met collega's, maar ook met veel anderen die sociaalwetenschappelijke data verzamelen aan wil bijdragen. Daarbij wil ik werken aan 3 brede thema's waar ik voor elk een voorbeeld van zal geven.

Wat ga ik doen

1. Ten eerste, de kwaliteit van bronnen zo goed mogelijk maken als de onderzoeker controle heeft over het onderzoeksproces
2. Als tweede thema: De kwaliteit van nieuwe data bestuderen, en ook kunnen beslissen hoe we data goed kunnen combineren of integreren
3. Als laatste thema: werken aan Concrete manieren om data te combineren en integreren.

Voordat ik begin met een voorbeeld waarin we hebben gewerkt aan data-integratie, eerst een meer klassiek voorbeeld dat laat zien dat de wereld veranderd. Want niet alles is Big Data, en ook de traditionele manier van onderzoek heeft nog toekomst.

Wat te doen:

Kwaliteit van bronnen zo goed mogelijk maken



Lugtig, P., Lensvelt-Mulders, G.J.L.M., R. Frerichs and Greven, A. (2011). [Estimating nonresponse bias and mode effects in a mixed-mode survey](#). *International Journal of Market Research*, 53, 669-686.

7

Onze onderzoeksgroep in Utrecht maakt deel uit van het Core Scientific Team; zeg maar de stuurgroep van de European Social Survey. Dit is waarschijnlijk het belangrijkste Europese sociaalwetenschappelijke onderzoeksproject van de laatste 20 jaar. Elke twee jaar worden ongeveer 40.000 mensen uit 31 Europese landen geïnterviewd over wat zij vinden van zaken die spelen in de politiek, welvaartsverdeling, migratie, en allerlei andere issues die voor psychologen, sociologen en politicologen van heel groot belang zijn. Dit onderzoek werd traditioneel altijd face-to-face uitgevoerd, interviewers

kwamen thuis mensen interviewen. Op dit moment verandert de ESS naar een combinatie van interviews die mensen zelf doen via Internet of op papier. Waar wij de komende jaren aan gaan werken is te zorgen dat data van voor de transitie vergelijkbaar blijven met data die in de toekomst met de nieuwe methode worden verzameld. Ik heb hier al in mijn proefschrift een methode voor bedacht en toegepast op een klein Nederlands onderzoek, en nu gaan we deze toepassen op het grootste sociaalwetenschappelijke onderzoek in Europa om te zorgen dat data uit deze studie als het even lukt beter worden dan hiervoor, en ook om ervoor te zorgen dat data over de tijd heen vergelijkbaar blijven.

Het tweede thema binnen mijn leerstoel sluit aan bij waar ik het al eerder over had. Hoe goed zijn al die nieuwe databronnen eigenlijk? Ook hier weer een voorbeeld naar mobiliteit.

Hoe weten we nu eigenlijk hoe gaat die data zijn? Of preciezer, hoe accuraat, relevant en interpreteerbaar die data precies zijn? Hoe goed of slecht meet deze data het reisgedrag van Nederlanders tijdens de Covid pandemie? Dat heb ik helemaal niet uitgelegd. En dat is met een reden: het is heel lastig te achterhalen hoe goed deze data nu eigenlijk is. Want de data zijn niet toegankelijk, Google vertelt ook niet precies hoe de data precies zijn gecreëerd. Dus wat ook echt nodig is, is dat we in de wetenschap onderzoek naar de kwaliteit van al deze nieuwe digitale data. Niet allen mobiliteitsdata, maar bijvoorbeeld ook data die via sociale media wordt gebruikt om iets te kunnen zeggen over meningen van mensen, of browse-gedrag die iets vertellen over wat mensen online doen.

Een goede manier om kwaliteit te onderzoeken is om data naast andere data te leggen die ongeveer hetzelfde moeten meten ander mobiliteitsonderzoek te leggen, en te kijken waar ze overeenkomen en verschillen. Dit is de tweede pijler van wat ik wil doen. Onderzoek doen naar hoe goed en hoe bruikbaar deze data nu eigenlijk zijn. Dat is iets wat veel te weinig gebeurt, en iets dat echt nodig is in een tijd waarin digitale data, die vrijwel altijd privaat wordt verzameld, steeds belangrijker wordt en waarin mijns inziens te weinig kritische vragen worden gesteld bij wat we nu allemaal aan die data hebben.


Wat te doen: *Hoe goed is kwaliteit van nieuwe data?*



Verkeerslussen



Afstand woon-werk



Wie kiest welk vervoersmiddel?

Vervoersmiddel	Tijd	Afstand	Kilometer of afstand
1 Bicyclist	10-30	10-45	5,0
2 Car	10-45	10-45	2000,0
3 Train	10-45	10-45	Kilometer
4			

Bostanci, I., Gootzen, Y. & Lugtig, P. (2023). [Data Linkage to Validate and Calibrate Traffic Estimations on a Nationwide Scale: A Framework for Official Statistics](#). CBS discussion paper.

8


Op het scherm zien jullie een voorbeeld van een onderzoek dat is uitgevoerd door Inan Bostanci, oud-student van onze Master, en begeleid door mij en Yvonne Gootzen van het Centraal Bureau voor de Statistiek. In dit onderzoek zijn allerlei verschillende bronnen aan elkaar geknoopt en de centrale vraag was hoe dat te doen. U ziet hier links bijvoorbeeld verkeerslusdata uit de grote wegen die niks anders doen dan het aantal passerende voertuigen tellen. Maar het CBS heeft nog veel meer data, bijvoorbeeld de afstanden van huis naar werk, en vragenlijsten die de voorkeuren voor vervoersmiddelen die mensen hebben meten. En hoe die voorkeuren verschillen per regio, maar bijvoorbeeld ook zaken als leeftijd. Je kunt al die data combineren om uiteindelijk te kunnen komen tot bijvoorbeeld schattingen van verkeersdrukke op alle wegen in Nederland, en we leggen uit in het paper hoe we dat doen. Maar dat was voor mij niet het belangrijkste. Het belangrijkste was dat we leerden hoe je de beperkingen van elke databron kunt aanvullen met informatie uit andere bronnen en hoe je de kwaliteit van elke bron goed kunt evalueren door ze naast andere bronnen te leggen

Als je eenmaal duidelijk hebt hoe goed verschillende databronnen nu precies zijn, dan is de volgende logische stap dat je nadenkt hoe je die bronnen precies kunt samenvoegen. Dit wordt het derde thema binnen mijn leerstoel. Hier een ander voorbeeld waar we in Utrecht de afgelopen 10 jaar aan hebben gewerkt met het Centraal voor de Statistiek. Een belangrijk deel van dat onderzoek richtte zich op hoe je mobiele telefoons goed zou kunnen inzetten voor het maken van allerlei officiële statistieken.

In Nederland worden al sinds de jaren '70 dagboekstudies gedaan die door het CBS worden uitgevoerd: mensen krijgen de vraag of ze van een periode – twee dagen of een week al hun reizen willen bijhouden. U zag net al een plaatje van een vragenlijst. Mensen moeten voor elke reis de startlocatie, en eindlocatie, de tijd, of de reis met de fiets, auto, trein, bus etc. bijhouden. Dat is heel intensief voor respondenten.

Wat te doen:

Combineren van traditionele en nieuwe data



McCool, D., Lugtig, P., Mussman, O. & Schouten, J.G. (2021). [An app-assisted travel survey in official statistics. Possibilities and challenges](#). *Journal of Official Statistics*, vol. 37, 149-170. 10.2478/jos-2021-0007.

In 2018 en 2022 hebben we testen gedaan om dit reisonderzoek anders op te zetten. Centraal staat hier de locatiesensor in mobiele telefoons. Door mensen een week lang te volgen via hun mobiele telefoons kunnen we veel betere data krijgen over iemand reisgedrag. Je kunt dan bijvoorbeeld precies zien hoe laat iemand weggaat en aankomt, maar ook welke route iemand precies neemt. In het onderzoek wordt op basis van locatiedata voor de mensen die meedoen aan het onderzoek automatisch een dagboek gevormd van een dag, en vervolgens kunnen mensen – als ze willen – nog extra data meegeven, zoals wat het doel van de reis was die ze hebben gemaakt. Zo'n methode leidt ook tot een lagere respondentbelasting.

Zelf is dit denk ik een geslaagd voorbeeld van hoe je verschillende databronnen combineert. We gebruiken de mobiele telefoon om relevantere data over reisgedrag te krijgen. We gebruiken vragen waar we informatie niet goed af kunnen leiden uit locatiegegevens. En we kunnen analyseren wie er wel en niet meedoen met het onderzoek aan de hand van allerlei andere gegevens die het CBS heeft, en op die manier corrigeren voor nonrespons.

Onderwijs

Behalve onderzoeker ben ik ook docent. Ik hou van lesgeven over onderwerpen als regressieanalyse en hoe je een vragenlijst opstelt, maar ik vind dat we toe zijn aan veranderingen in het onderwijs aan sociale wetenschappers over data.

Data speelt een heel grote rol in beleidsvorming, en veel van onze studenten gaan uiteindelijk niet zelf onderzoek doen, maar wel veel met cijfers werken, bijvoorbeeld als beleidsmedewerker.

We leren studenten op dit moment onvoldoende hoe ze met al die data om moeten gaan. In een wereld waarin we meer en meer worden overspoeld door cijfers; niet alleen van renommeerde onderzoeksinstituten zoals het Sociaal Cultureel Planbureau of het CBS, maar ook door commerciële partijen, is het ontzettend belangrijk dat studenten die afstuderen weten hoe data wordt geproduceerd, wat je met data kan, maar ook wat je met data niet kunt. De AI modellen die we steeds meer gebruiken zijn gebouwd op basis van heel grote datasets, en gebruiken uiteindelijk statistiek om een tekst te herschrijven, een mooi plaatje te maken, of de ondertitels vandaag te maken. We moeten studenten niet alleen leren wat ze wel en niet mogen met taalmodellen tijdens hun studie, maar het is belangrijk dat iedereen op de universiteit weet hoe die modellen werken zodat ze ook de beperkingen van die modellen begrijpen. Voor wat wordt genoemd 'datageletterdheid' is op dit moment in het curriculum van studenten veel te weinig ruimte, en ik zie het als mijn plicht om daar de komende jaren ook een bijdrage aan te leveren.

Maar voordat jullie allemaal denken dat ik sociale wetenschappers niet zo hoog heb zitten; dat is niet zo. Goed sociaalwetenschappelijk onderzoek doen is moeilijk. Zoals een collega van mij uit de Verenigde Staten ooit zei bij de opkomst van allerlei online websites waarmee je zelf een vragenlijst kunt maken: "Elke idioot kan nu een vragenlijstonderzoek doen, en elke idioot doet dat ook". Ik zie elke week weer dat mensen denken dat ze wel even een enquête kunnen opstellen. Dat geldt niet voor de meeste studenten sociale wetenschappen.

Sociale wetenschappers zijn heel goed in het denken over de hele maatschappij. Bijvoorbeeld: ze leren niet alleen wat een goede enquêtevraag is en wat niet, maar denken dan ook of iedereen die vragen wel kan beantwoorden, en of iedereen een enquêtevraag op dezelfde manier begrijpt. Dit soort vaardigheden zijn juist het soort vaardigheden dat in een wereld waar ongelijkheid groter wordt, en er steeds geavanceerdere digitale tools komen ontzettend belangrijk zijn. Ik denk ook echt dat de sociale wetenschappen veel hebben toe te voegen aan hoe we AI kunnen en zouden moeten gebruiken in onze maatschappij.

Slot en dankwoord

Dit brengt me bij het volgende. Wetenschap kun je niet alleen doen. Ik sta hier nu, maar dat is dankzij ontzettend veel mensen binnen en buiten de universiteit met wie ik samengewerkt, die me hebben gesteund of die me hebben geïnspireerd in mijn onderwijs en onderzoek. Zonder hen had ik zeker niet gestaan.

Ik geloof er sterk in dat zowel onderwijs als onderzoek beter worden als je dat in een team doet. In een team kunnen mensen je soms helpen met dingen die je eigenlijk niet zo heel goed kunt (mijn collega's hebben nu allemaal wel iets in hun hoofd denk ik). Maar vooral is teamwerk productiever, en ik denk ook dat de kwaliteit van het werk er beter van wordt als je dat samen doet. Ik wil heel veel mensen bedanken met wie ik in de afgelopen 20 jaar heb samengewerkt. Op het gevaar af dat ik sommige mensen tekort doe:

Allereerst, mijn collega-hoogleraren bij de afdeling, de faculteit en het faculteitsbestuur dat ervoor hebben gezorgd dat ik hier nu sta als hoogleraar. Ik dank jullie voor het vertrouwen dat jullie me hebben gegeven, en ik hoop niet dat jullie daar nog spijt van gaan krijgen.

Slide foto

Dan, mijn collega's uit de datakwaliteit onderzoeksgroep. Jullie zijn de beste collega's om samen onderzoek mee te doen. Het voelt eigenlijk nooit als werk om met jullie papers of subsidievoorstellen te schrijven. We delen allemaal een liefde voor het organiseren van workshops en congressen, en voor mij was het organiseren van het ESRA congres, hier in Utrecht vorige zomer echt een hoogtepunt uit mijn hele werk op de UU. Ik hoop dat we nog jaren samen kunnen blijven werken aan het verbeteren van datakwaliteit. Er valt nog genoeg te doen. Een speciaal dankwoord ook aan het Centraal Bureau voor de Statistiek en dan vooral Barry Schouten en Vera Toepoel voor alle jaren waarin ik heel fijn met het CBS heb samengewerkt.

Ik wil ook al mijn collega's bedanken met wie ik samen onderwijs geef. De laatste jaren geef ik wat minder onderwijs, en eigenlijk vind ik dat heel jammer, want het allerallerleukst aan mijn werk vind ik denk ik het geven van een werkgroep of een computerpracticum waarin ik zie dat studenten iets leren. Dat ze eindelijk begrijpen waarom we ze nu al weken onderwijs geven

over regressie, als ze zien hoe ze daarmee theorieën kunnen testen. Of dat een vragenlijst zoveel beter wordt van cognitieve interviews. Ik wil al mijn collega's, maar ook de studenten die ik elk jaar lesgeef, en waarvan er nu ook een aantal hier zijn bedanken voor al het mooie onderwijs dat we al jaren geven.

Slide M&S

Voor mij is werk meer dan alleen onderwijs geven en onderzoek doen. Het meeste leer ik en waardeer ik de gesprekken bij de koffieautomaat, vooral 's ochtends vroeg waar we het vaak hebben over het leven, maar ook over het werk; waar studenten tegenaan lopen, welke nieuwe R-packages er zijn, of het nou zinvol is of niet om assumpties in statistiek te toetsen, of wat er speelt op de universiteit. Ik ben heel blij dat ik bij de afdeling Methodologie en Statistiek werk; waar het geven van onderwijs voor veel mensen het belangrijkste is aan werken op de universiteit, en ook waar iedereen met liefde een praktisch probleem oplost, of voor elkaar klaarstaat als iets even tegenzit. Ik prijs me gelukkig dat ik al zo lang werk met zoveel fijne collega's.

Heel belangrijk voor mij zijn mijn promotoren Gerty Lensvelt en Joop Hox geweest. Ik ben heel bij dat jullie er vandaag ook zijn. Gerty, van jou heb ik geleerd dat het goed is na te denken over ambities, en hoe om te gaan met de 100.000 dingen die als wetenschapper op je af komen. Joop, van jou heb ik ontzettend veel geleerd over statistisch modelleren, en over hoe je altijd nieuwsgierig moet blijven naar nieuwe methoden, en statistische methoden.

Werk is voor mij belangrijk, maar werk is niet mijn leven. Nog belangrijker dan werk zijn de mensen buiten het werk. Mijn vader – die helaas al lang overleden is – en mijn moeder hebben me van jongs af aan gestimuleerd om nieuwe dingen te doen, me heel veel ruimte gegeven, en me altijd gesteund in de keuzes die ik maakte in het leven. Dank jullie wel. Mijn vrienden van de middelbare school, studie en de vrienden van talloze concerten feestjes en festivals. Jullie maken het leven leuk en licht. Wouter, Ellen en de hele familie Birkhoff, die er altijd zijn als er iets moet worden gebouwd of er iets te vieren valt.

En dan zijn hier vooraan mijn kinderen Brun en Nore. Brun moest laatst voor de middelbare school een dag meelopen op mijn werk. Brun; je zat de hele dag naast me terwijl ik alleen maar aan het e-mailen en overleggen was, en ik weet niet of jij het nu nog ambieert zelf ooit naar de universiteit te gaan. Je bent een

open boek, niet alleen voor mij maar voor iedereen, en zo ontzettend lief. Ik hoop dat je altijd zo blijft.

Nore mijn drukke duizendpoot. Altijd bezig met een nieuw knutselproject of een baksel, maar ook altijd in om samen iets te doen. Ik bewonder je levenslust, en dat je altijd precies weet wat je wilt en waarom.

En dan tenslotte; Marleen. Al 18 jaar zijn we samen. Ik bewonder je om je doorzettingsvermogen, je focus op wat je wilt, en al de liefde die je geeft. Sorry voor al die avonden die ik de laatste tijd heb doorgewerkt. Vanavond, wil ik alvast wel beloven, ga ik dat niet doen.

Ik heb gezegd.